S2 | Projet cybersécurité

Analyse de texte et question-réponse

Rapport de cadrage : Business Understanding et préparation des données

Module : Advanced Learning for Text and Graph Data
Date : 29 octobre 2026
Statut : proposition méthodologique, avant entraînement et évaluation.

Finalité

Aider un analyste à comprendre des descriptions de menaces, retrouver des informations pertinentes et explorer les relations entre menaces, vulnérabilités, logiciels et cibles, à partir de documents traçables.

Le livrable associe classification NLP, extraction d’entités, graphe de connaissances, apprentissage sur graphe et question-réponse avec Graph-RAG. Le notebook associé prépare les données ; il ne prétend pas livrer des modèles déjà entraînés.

Principe de correspondance

Un objectif métier décrit une amélioration utile à un utilisateur. Un objectif data science décrit une capacité mesurable du système permettant cette amélioration. « Créer un chatbot LLM » est donc un objectif technique ; le besoin métier associé est de faciliter l’accès à des réponses fiables.

1. Business Understanding

Contexte. Les informations de cybersécurité sont nombreuses, dispersées et rédigées sous des formes variées. Une consultation manuelle rend difficile le rapprochement de documents et la justification des réponses.

Utilisateurs cibles. Analystes de sécurité et étudiants en cybersécurité. Le système constitue une aide documentaire, dont les conclusions doivent rester vérifiables.

Périmètre. Analyse de textes et questions-réponses ; aucune détection de trafic réseau en temps réel n'est démontrée par ce corpus. Les textes pédagogiques ne seront pas présentés comme des incidents réellement survenus.

Situation de départ. Le lien fourni mène à un corpus anglophone de questions-réponses avec les champs system, user et assistant. Le viewer affiche environ 2,41 k lignes et un split train. Il n'affiche pas d'annotations de classes, de NER ou de relations. Ces observations proviennent de la fiche consultée le 29 octobre 2026 [1] ; le notebook recalculera les effectifs.

Résultats métiers attendus

Réduire l'effort de recherche ; rendre le tri des textes plus cohérent ; faciliter l'identification des informations utiles ; rendre visibles les relations documentées ; fournir des réponses justifiées.

Mesure métier proposée. Comparer une recherche manuelle et l'application sur les mêmes scénarios, en alternant l'ordre pour limiter l'effet d'apprentissage. Relever le temps, la réussite et la satisfaction. Les seuils ci-après sont des cibles proposées, à valider avec l'enseignant, et non des résultats obtenus.

2. Tableau de correspondance métier / technique

Chaque identifiant métier est relié à un objectif data science précis et à une preuve attendue.

Objectif métier	Objectif data science / technique	Évaluation et preuve
OM1 - Accélérer le tri des descriptions de menaces et incidents.	DS1 - Développer une classification thématique ou multilabel. Comparer TF-IDF + régression logistique avec un Transformer.	Métier : temps de tri et corrections. Technique : macro-F1, précision et rappel par classe sur annotations vérifiées.
OM2 - Faciliter le repérage des informations de sécurité dans les textes.	DS2 - Extraire et normaliser IP, CVE, logiciels et malwares. Combiner règles et NER selon les annotations disponibles.	Métier : temps de repérage. Technique : F1 des entités avec correspondance exacte sur un jeu annoté.
OM3 - Retrouver rapidement des descriptions comparables.	DS3 - Construire des embeddings et un moteur de similarité ; comparer recherche lexicale et recherche vectorielle.	Métier : pertinence jugée par l'utilisateur. Technique : Recall@5 et nDCG@5 sur requêtes jugées manuellement.
OM4 - Comprendre les liens entre menaces, vecteurs et cibles.	DS4 - Construire un graphe traçable ; entraîner un GNN/GTN pour classer les documents ou prédire des liens selon les données.	Métier : réussite de scénarios relationnels. Technique : précision des relations ; macro-F1 du GNN comparé au texte seul.
OM5 - Accéder à des réponses compréhensibles et justifiées.	DS5 - Créer un chatbot LLM avec Graph-RAG, citations et abstention. Comparer au RAG vectoriel seul.	Métier : réponses utiles et temps de recherche. Technique : exactitude, appui des citations, taux d'abstention appropriée.

3. Critères de réussite et limites

Correspondance	Cible proposée à valider
OM1 / DS1	Réduire de 20 % le temps médian de tri ; macro-F1 ≥ 0,80 sur un test indépendant.
OM2 / DS2	F1 entités ≥ 0,85 ; mesurer séparément CVE, IP et entités apprises.
OM3 / DS3	Recall@5 ≥ 0,80 ; évaluer avec des jugements de pertinence indépendants.
OM4 / DS4	100 % des relations factuelles affichées reliées à un passage ; comparer GNN et modèle texte sur le même protocole. Aucun gain garanti.
OM5 / DS5	≥ 80 % de réponses exactes et étayées sur un jeu expert ; ≥ 90 % d'abstentions correctes pour les questions sans réponse dans le corpus.

Ces seuils dépendent du volume et de la qualité des annotations. Aucun score ne peut être annoncé avant exécution. Le temps métier doit être mesuré sur des participants et scénarios comparables.

Décisions de cadrage

La taxonomie sera définie après exploration : phishing, malware et vulnérabilité ne sont pas nécessairement des catégories exclusives. Une classe « autre » et plusieurs étiquettes peuvent être nécessaires.

Le corpus Q/R suffit à prototyper une recherche documentaire. Les objectifs sur de vrais incidents et sur les liens logiciel-CVE nécessiteront des documents appropriés et des annotations vérifiées. Une réponse du corpus ne constitue pas automatiquement une référence technique fiable.

4. Data Understanding et préparation

Acquisition. Charger Hugging Face via la bibliothèque datasets ; conserver une copie brute et la révision exacte du dépôt. Télécharger un dataset n’est pas du scraping. La collecte HTML complémentaire est un processus distinct, optionnel, avec URL et date.

Audit. Vérifier les champs, valeurs manquantes, longueurs, doublons et incohérences question-réponse. La présence de balises think ou de réponses hors sujet motive une revue humaine. Les alertes automatiques ne remplacent pas cette revue.

Nettoyage prudent. Normaliser Unicode et espaces sans supprimer les identifiants CVE, les points des IP, la ponctuation des versions ou les fragments techniques. Conserver le texte brut ; retirer les blocs think uniquement de la copie nettoyée et marquer les cas incomplets.

Tokenisation. Une tokenisation exploratoire préserve les CVE et IP. La tokenisation Transformer utilise ensuite le tokenizer du modèle retenu. La suppression des stop words et la lemmatisation ne sont pas imposées à ce dernier.

Découpage. Former des passages avec chevauchement en gardant doc_id, chunk_id et position. Les occurrences extraites par expressions régulières sont des candidats, pas des annotations NER validées.

Annotations et séparation. Prévoir labels, validation humaine, entités et relations avec passages justificatifs. Regrouper doublons exacts et proches avant séparation train/validation/test. Le notebook produit un découpage provisoire groupé par question normalisée ; les quasi-doublons doivent encore être contrôlés.

Exports. Documents nettoyés, audit qualité, jetons, passages, entités candidates, fichiers d’annotation et manifeste de provenance. Les données non validées ne doivent pas alimenter une évaluation finale.

5. Collecte web complémentaire et graphe

Le notebook contient une fonction de collecte HTML limitée aux URL explicitement configurées. Elle vérifie robots.txt, fixe un délai, utilise un timeout et un cache, enregistre le HTML brut et sa provenance. Elle reste désactivée par défaut. Vérifier également les conditions de réutilisation de chaque source.

Privilégier les avis et fiches officiels si le corpus manque de relations logiciel-vulnérabilité. Lorsqu'une API ou un flux structuré existe, le préférer au scraping HTML. Une page collectée nécessite encore une revue de pertinence et de qualité.

Schéma de graphe proposé

Type de relation	Condition de création
Document → MENTIONNE → Entité	Présence dans un passage conservé avec positions.
Vulnérabilité → AFFECTE → Logiciel	Relation explicitement documentée et vérifiée ; pas une simple cooccurrence.
Incident → UTILISE → Vecteur / Menace	Uniquement pour un incident identifié comme tel dans une source.
Incident → CIBLE → Actif	Cible explicitement attestée dans le document.
Document → SIMILAIRE_A → Document	Lien calculé, avec score et méthode ; distinct d'une relation factuelle.

Sur ce corpus initial, commencer par un graphe document-entité. Ne créer des nœuds incidents qu'avec des descriptions d'incidents. Pour le GNN, annoncer le cadre transductif ou inductif et prévenir les fuites par les labels, les arêtes ou les documents de test.

6. Plan de réalisation et protocole

Étape	Sortie attendue
1 - Business Understanding	Besoins, correspondances OM/DS, critères et périmètre : présent rapport.
2 - Compréhension et préparation	Notebook associé, exports et revue humaine des données.
3 - Modélisation NLP	Baselines, Transformer, extraction d'entités et embeddings.
4 - Graphe et apprentissage	Graphe sourcé, visualisation et comparaison GNN / texte seul.
5 - Question-réponse	RAG vectoriel puis Graph-RAG ; citations et abstention.
6 - Évaluation et démonstration	Mesures techniques et métiers, limites, application et rapport final.

QA. Construire un jeu de questions indépendant, incluant questions sans réponse et questions relationnelles. Masquer toute réponse de test dans un protocole d'entraînement QA ; distinguer explicitement le corpus documentaire consultable des réponses de référence.

Comparaisons. Garder les mêmes requêtes et critères pour les baselines. Mesurer le coût et la latence en complément de la qualité. Ne pas présenter l'usage d'un LLM ou d'un graphe comme une preuve de performance.

Références et statut du notebook

[1] AlicanKiraz0, Cybersecurity-Dataset-v1, Hugging Face, fiche consultée le 29/10/2026 : huggingface.co/datasets/AlicanKiraz0/Cybersecurity-Dataset-v1

[2] Consigne S2 fournie par l'équipe : NLP, embeddings, extraction d'entités, graphe entité-incident, GNN/GTN et Graph-RAG / QA.

Le notebook est un livrable de préparation exécutable sur la machine de l'équipe avec accès Internet. Sa structure et la syntaxe des cellules sont vérifiées ; le téléchargement du corpus et des modèles n'a pas été exécuté ici. Les statistiques et performances seront produites lors de son exécution.